

SESIÓN 6

Semana 2 · Prompting Avanzado y Razonamiento con IA

Self-Consistency

para Mejorar Confiabilidad

¿Cuándo confiar en la respuesta de la IA?

Edwin Puertas, PhD
epuerta@utb.edu.co



AGENDA

Sesión 6 · Self-Consistency



Variabilidad IA



Self-Consistency



Votación y consenso



Taller satisfacción



¿Cuándo confiar?



Cierre y tarea

Lo que trabajaremos hoy

B1

¿Por qué la IA da respuestas distintas?

30'

Temperatura, aleatoriedad y variabilidad de modelos

B2

Qué es Self-Consistency

30'

Concepto, origen y cuándo aplicarlo

B3

Demostración en vivo

30'

Mismo prompt 3 veces → comparar → seleccionar

B4

Taller individual

30'

Dataset de satisfacción + prompt + 3 respuestas

B5

Taller en equipo

30'

Rúbrica de selección + versión mejorada

B6

Cierre: ¿cuándo confiar en la IA?

30'

Reflexión, tarea y conexión Sesión 5



¿Por qué la IA da respuestas distintas?

B1 · 30 min

🌡 El parámetro TEMPERATURA

0.0

Determinista

Siempre la misma respuesta.
Máxima consistencia, poca creatividad.

0.7

Balanceada

Ligeras variaciones entre respuestas.
Equilibrio útil para análisis.

1.5

Creativa/Aleatoria

Respuestas muy distintas.
Mayor creatividad, menor consistencia.

⚡ **Clave:** Incluso con temperatura baja, los modelos grandes generan variaciones sutiles. Self-Consistency aprovecha esta variabilidad para encontrar la respuesta más robusta.



Otras fuentes de variabilidad



Muestreo estocástico

El modelo 'elige' entre probabilidades de palabras, no siempre la más probable.



Redacción del prompt

Pequeñas variaciones en cómo se pide algo cambian el resultado.



Largo de la respuesta

Pedir más o menos detalle altera el razonamiento incluido.



Orden del contexto

En prompts con múltiples ejemplos, el orden afecta el output.



¿Qué es Self-Consistency?

B2 · 30 min

Self-Consistency (Wang et al., 2022) es una técnica que consiste en ejecutar el **mismo prompt múltiples veces**, comparar las respuestas generadas y **seleccionar la más sólida y coherente** mediante votación o criterios explícitos. Aumenta la confiabilidad sin cambiar el modelo.



✓ Cuándo USAR Self-Consistency

- ✓ Tareas analíticas complejas con múltiples interpretaciones posibles
- ✓ Decisiones importantes donde el error tiene alto costo
- ✓ Análisis de texto, clasificación y síntesis de datos
- ✓ Verificación de razonamientos CoT en problemas críticos

⚠ Cuándo NO usar / limitaciones

- ✗ Tareas simples con respuesta única y clara (no agrega valor)
- ✗ Cuando el tiempo/costo de ejecución múltiple no está justificado
- ✗ Si todas las respuestas son inconsistentes: revisar el prompt primero
- ✗ No reemplaza la verificación con fuentes externas



Votación y Consenso entre Respuestas

B2–B3



Ejemplo: mismo prompt ejecutado 5 veces — ¿Cuál es la categoría de sentimiento de este comentario? 'El servicio fue tan pausado y el personal tan reservado que la experiencia se vuelve difícil de olvidar.'

Ejecución	Clasificación	Justificación de la IA	Observación
Ejecución 1	Negativo	'El servicio fue lento y el personal poco amable'	El modelo identificó tono negativo dominante.
Ejecución 2	Negativo	'Frustración por espera y trato del personal'	Coincide en negativo, distinta justificación.
Ejecución 3	Mixto	'Hay elementos negativos pero también de contexto'	Vacilación — identifica matices.
Ejecución 4	Negativo	'Sentimiento predominantemente negativo'	Tercera vez: negativo con alta confianza.
Ejecución 5	Negativo	'Tono claramente desfavorable hacia el servicio'	Cuarta coincidencia.



Resultado de votación por mayoría

Negativo: 4/5 ejecuciones (80%) → SELECCIÓN por mayoría ✓

La ejecución 3 (Mixto) es un outlier — analiza si el prompt fue ambiguo o si hay información válida en esa respuesta.



Criterios de selección

1. Frecuencia (mayoría absoluta o relativa)
2. Completitud del razonamiento
3. Ausencia de contradicciones internas
4. Coherencia con los datos del problema



Votación y Consenso entre Respuestas

B2-B3

1 — ROL + CONTEXTO

¿Quién eres? ¿Cuál es la situación? ¿Qué conocimiento de fondo tiene la IA?

"Eres un analista académico de la UTB. La vicerrectoría necesita elegir un programa de formación docente."

2 — DATOS

Las opciones, registros o información que la IA debe razonar. Estructurados o en texto libre.

"Programa A: \$3.2M, 80h, virtual, cal.4.2, impacto alto. Programa B: \$1.9M, 40h, presencial, cal.3.5, impacto medio..."

3 — INSTRUCCIÓN CoT

La frase que activa el razonamiento explícito. Debe pedir evaluación paso a paso con criterios.

"Para cada programa evalúa paso a paso: costo (30%), calidad (40%), impacto (20%), horas (10%). Muestra tu razonamiento."

🗳️ Resultado de votación por mayoría

4 — SOLICITUD DE CONCLUSIÓN

Pide la decisión final, sus razones y el orden de prioridad. Debe derivar del razonamiento anterior.

"Indica cuál es el mejor programa, justifica con los puntajes calculados y explica por qué descartaste los demás."



Dataset del Taller: Satisfacción de Clientes

B3–B4



Opción A: Dataset Sintético (incluido)

satisfaccion_clientes_sintetica.xlsx · 30 registros ficticios

Campo	Tipo	Descripción
id_cliente	Texto	ID ficticio del cliente (CLI-001...CLI-030)
fecha_encuesta	Fecha	Período: enero–marzo 2024
canal	Categorico	Presencial / Virtual / Telefónico / App
calificacion	Entero (1–5)	Satisfacción general. 1=Muy insatisfecho, 5=Muy satisfecho
comentario	Texto libre	Opinión abierta del cliente (ficticia, en español)
segmento	Categorico	Empresarial / Personal / Estudiante / Gobierno
tiempo_resolucion_min	Entero	Minutos que tomó resolver la solicitud (15–180)
recomendaria	Booleano	¿Recomendaría el servicio? Sí / No



Opción B: Dataset de Libre Acceso

Amazon Product Reviews

https://cseweb.ucsd.edu/~jmcauley/datasets/amazon_v2/

Millones de reseñas con calificaciones y texto libre. Ideal para análisis de sentimiento y Self-Consistency con clasificación.

📦 Múltiples subsets (desde 5K registros) · Cols: reviewerID, asin, reviewText, overall (1–5), summary, unixReviewTime

Yelp Open Dataset

<https://www.yelp.com/dataset>

Reseñas de negocios con rating, texto, ciudad y categoría. Muy usado en NLP y análisis de satisfacción.

📦 ~7M reseñas, filtrable · Cols: review_id, stars, text, date, business_id, user_id

Twitter US Airline Sentiment

<https://www.kaggle.com/datasets/crowdflower/twitter-airline-sentiment>

14K tweets sobre aerolíneas etiquetados como positive/neutral/negative. Perfecto para clasificación con SC.

📦 14.640 registros. CSV descargable · Cols: airline_sentiment_confidence, airline_text,



Para este taller se usa el dataset sintético — no requiere descarga ni registro.



Demostración: Mismo Prompt — 3 Respuestas

B3 · 30 min

 Prompt de demostración (dominio universitario / satisfacción de servicios UTB)

"Eres un analista de experiencia estudiantil de la UTB. Analiza los siguientes 5 comentarios de estudiantes sobre el servicio de matrícula. **Identifica los 2 principales problemas, el sentimiento dominante y una recomendación de mejora. Piensa paso a paso.**"

R1 Problemas: (1) Tiempos de espera excesivos en el sistema online. (2) Falta de información sobre requisitos. Sentimiento: Predominantemente negativo con frustración notable. Recomendación: Simplificar el portal y mejorar la comunicación preventiva.

Razonamiento claro, bien estructurado, dos problemas específicos.

R2 Identifico tres problemas: espera en el sistema, documentación confusa y falta de respuesta del personal. Sentimiento: Negativo. La principal acción sería capacitar al personal en atención al usuario.

Identifica 3 problemas (no 2 como se pedía). Recomendación diferente.

R3 Los problemas más mencionados son la lentitud del sistema y la documentación. El tono es crítico. Sugiero revisar la plataforma y crear una guía de usuario actualizada.

Coherente con R1. Mismo foco pero recomendación adicional (guía).

Análisis de Satisfacción

con Self-Consistency

INDIVIDUAL (Bloque 4 · 30 min)

1. Abre satisfaccion_clientes_sintetica.xlsx
2. Diseña un prompt CoT para analizar los comentarios del segmento que elijas
3. Ejecuta el mismo prompt exactamente 3 veces sin modificarlo
4. Registra las 3 respuestas en tu ficha de comparación
5. Identifica diferencias clave y elige la respuesta más sólida

EQUIPO (Bloque 5 · 30 min)

1. Comparen sus tablas de comparación de respuestas
2. Construyan una rúbrica de 4 criterios para seleccionar entre respuestas
3. Apliquen la rúbrica a sus 3 respuestas individuales
4. Preparen 1 hallazgo clave sobre cuándo la IA fue consistente o no

30'

Individual

30'

Equipo



Rúbrica de Selección entre Respuestas de IA

B5 · Equipo

1 Completitud

¿La respuesta aborda todos los puntos pedidos en el prompt?

1 Insuf.

2 Básico

3 Adec.

4 Exce.

Nivel 1: Ignora puntos importantes del prompt | **Nivel 4:** Cubre todos los puntos con profundidad

3 Consistencia con los datos

¿Las conclusiones están respaldadas por los datos del problema?

1 Insuf.

2 Básico

3 Adec.

4 Exce.

Nivel 1: Conclusiones no soportadas por los datos | **Nivel 4:** Cada afirmación vinculada a datos concretos

5 Ausencia de sesgos/alucinaciones

¿La respuesta incluye información falsa o inferencias no válidas?

1 Insuf.

2 Básico

3 Adec.

4 Exce.

Nivel 1: Incluye datos inventados o errores factuales | **Nivel 4:** No hay alucinaciones detectables

2 Coherencia del razonamiento

¿El razonamiento interno es lógico y sin contradicciones?

1 Insuf.

2 Básico

3 Adec.

4 Exce.

Nivel 1: Contradicciones claras o saltos lógicos | **Nivel 4:** Razonamiento paso a paso sin inconsistencias

4 Accionabilidad

¿La respuesta genera conclusiones o recomendaciones útiles?

1 Insuf.

2 Básico

3 Adec.

4 Exce.

Nivel 1: Vaga, genérica, no accionable | **Nivel 4:** Específica, priorizada, lista para decidir

6 Coincidencia con otras ejecuciones

¿La respuesta coincide con la mayoría de las otras ejecuciones?

1 Insuf.

2 Básico

3 Adec.

4 Exce.

Nivel 1: Totalmente diferente a las demás (outlier) | **Nivel 4:** Coincide en puntos clave con 3+ ejecuciones



¿Cuándo Confiar y Cuándo Dudar de la IA?

B6 · Reflexión

Matriz de Confianza: Complejidad de la tarea × Consistencia de respuestas

CONFIAR CON REVISIÓN LEVE

Condición: Alta consistencia + Baja complejidad

Respuesta muy probablemente correcta. Revisión rápida suficiente.

REVISAR CON CUIDADO

Condición: Alta consistencia + Alta complejidad

Respuestas coinciden pero el problema es difícil. Verificar con experto o fuente secundaria.

REVISAR EL PROMPT

Condición: Baja consistencia + Baja complejidad

Si el problema es simple y las respuestas varían, el prompt es ambiguo. Reformular antes de decidir.

NO USAR SIN VALIDACIÓN

Condición: Baja consistencia + Alta complejidad

Máximo riesgo. Respuestas distintas en problema complejo = alta incertidumbre. Experto humano obligatorio.



La Revisión Humana como Capa Final



Lo que SOLO el humano puede aportar en la revisión final:



Contexto institucional

Sabe si la recomendación es viable en la cultura y las restricciones reales de la organización.



Verificación factual

Contrasta afirmaciones de la IA con fuentes confiables, especialmente en datos específicos o cifras.



Comunicación y responsabilidad

Quien firma la decisión es el humano. La IA es una herramienta de apoyo, no un decisor.



Ética y responsabilidad

Evalúa si la decisión puede afectar negativamente a personas o grupos. La IA no tiene ética propia.



Juicio de valor

Pondera aspectos intangibles: relaciones, reputación, impacto a largo plazo que los datos no capturan.



Mejora iterativa

Puede reformular el prompt, cambiar el contexto o pedir aclaraciones cuando la IA no converge.



Resultado · Tarea · Próxima Sesión

✓ Al finalizar esta sesión podrás:

- ✓ Explicar por qué la IA genera respuestas distintas
- ✓ Aplicar Self-Consistency ejecutando el mismo prompt múltiples veces
- ✓ Comparar y seleccionar la respuesta más sólida con criterios explícitos
- ✓ Construir una rúbrica de selección entre respuestas de IA
- ✓ Reconocer cuándo confiar y cuándo dudar de la IA
- ✓ Justificar el rol de la revisión humana como capa final

Tarea:

- 1 Elige un problema analítico real de tu trabajo (ventas, servicio, académico).
- 2 Diseña un prompt CoT para ese problema.
- 3 Ejecuta el mismo prompt al menos 3 veces sin modificar.
- 4 Registra las respuestas en la tabla de comparación.
- 5 Aplica la rúbrica de 6 criterios a cada respuesta.
- 6 Escribe un párrafo: ¿cuál respuesta elegiste y por qué?

Entrega antes de Sesión 5

→ Próxima sesión:

Sesión 6

Tree of Thoughts

Para problemas complejos

Explorar múltiples ramas de solución antes de elegir la más viable.

Conexión: usarás el problema de tu tarea de la Sesión 6 como punto de partida.