

# Análisis Exploratorio de Datos

## KNIME

### ¿Qué construirás en esta guía?

Dos ejercicios guiados paso a paso para explorar el dataset de 200 estudiantes ficticios de la UTB: análisis de riesgo académico por programa (Ejercicio 1) y perfilamiento de estudiantes destacados y en riesgo (Ejercicio 2) — usando estadísticas, filtros, agrupaciones y gráficas en KNIME.

| Atributo              | Descripción                                                |
|-----------------------|------------------------------------------------------------|
| Nivel                 | Básico — sin programación previa requerida                 |
| Dataset               | datos_academicos_UTB.csv (200 registros incluidos)         |
| Herramientas          | KNIME Analytics Platform Community Edition (gratuito)      |
| Duración              | 3-4 horas incluyendo ambos ejercicios                      |
| Resultado Ejercicio 1 | Tabla de riesgo por programa + gráfica de barras exportada |
| Resultado Ejercicio 2 | Perfil comparativo RIESGO vs DESTACADO en Excel multi-hoja |

## 1. El dataset: datos\_academicos\_UTB.csv

El archivo contiene 200 registros ficticios de estudiantes de la Universidad Tecnológica de Bolívar con 15 variables académicas y socioeconómicas. Los datos fueron generados con distribuciones realistas basadas en indicadores típicos de IES colombianas.

| Campo            | Tipo    | Ejemplo               | Descripción                  |
|------------------|---------|-----------------------|------------------------------|
| codigo           | String  | COD-IND-2021-0042     | Código único del estudiante  |
| nombre           | String  | Ana García Ruiz       | Nombre completo (ficticio)   |
| genero           | String  | M / F                 | Género del estudiante        |
| programa         | String  | Ingeniería Industrial | Programa académico           |
| semestre         | Integer | 4                     | Semestre actual (1-10)       |
| estrato          | Integer | 2                     | Estrato socioeconómico (1-6) |
| municipio_origen | String  | Cartagena             | Ciudad de procedencia        |

| Campo                | Tipo    | Ejemplo    | Descripción                                |
|----------------------|---------|------------|--------------------------------------------|
| tipo_beca            | String  | ICETEX     | SIN_BECA / ICETEX / EXCELENCIA / BIENESTAR |
| promedio_acumulado   | Double  | 3.42       | Promedio GPA (0.0 - 5.0)                   |
| asistencia_pct       | Double  | 78.5       | Porcentaje de asistencia (0-100)           |
| materias_reprobadas  | Integer | 2          | Materias reprobadas acumuladas             |
| creditos_cursados    | Integer | 72         | Créditos cursados hasta la fecha           |
| estado_academico     | String  | REGULAR    | RIESGO / SEGUIMIENTO / REGULAR / DESTACADO |
| satisfaccion_carrera | Double  | 3.8        | Satisfacción con la carrera (1-5)          |
| modalidad            | String  | Presencial | Presencial / Virtual / Mixta               |

#### Distribución de estados académicos en el dataset:

DESTACADO: 22 estudiantes (11%) · REGULAR: 84 (42%) · SEGUIMIENTO: 63 (32%) · RIESGO: 31 (16%)

## 1.1 Generar el dataset (si no lo tienes)

Si no tienes el archivo CSV del material de apoyo, puedes generarlo tú mismo con este script Python. Requiere Python 3.8+ instalado:

```
# Instalar dependencias (solo la primera vez):
pip install faker

# Luego ejecuta el script gen_datasets.py incluido en los materiales
# El script genera automaticamente datos_academicos_UTB.csv en la misma carpeta
```

## Ejercicio 1 — Análisis de riesgo académico por programa

**Objetivo:** identificar qué programas académicos tienen mayor concentración de estudiantes en estado RIESGO y SEGUIMIENTO, usando GroupBy, Statistics y Bar Chart en KNIME.

## Preguntas para responder en este ejercicio

| #          | Pregunta de negocio                                                                           |
|------------|-----------------------------------------------------------------------------------------------|
| Pregunta 1 | ¿Cuántos estudiantes hay en cada estado académico (RIESGO, SEGUIMIENTO, REGULAR, ¿DESTACADO)? |
| Pregunta 2 | ¿Cuál programa tiene el mayor porcentaje de estudiantes en RIESGO?                            |
| Pregunta 3 | ¿Cuál es el promedio acumulado promedio por programa? ¿Cuál es el más bajo?                   |

## Paso a paso — Ejercicio 1

PASO  
1

### Crear workflow y cargar el dataset

File → New Workflow → nombre: EDA\_Riesgo\_Academico\_UTB. Canvas vacío aparece.

Arrastra CSV Reader al canvas. Doble clic:

- File → Browse → selecciona datos\_academicos\_UTB.csv
- Has Column Header: activado | Delimiter: coma | Encoding: UTF-8

Ejecuta (F7). Verifica en Output View: 200 filas, 15 columnas.

PASO  
2

### Ver estadísticas generales con Statistics

Arrastra Statistics al canvas. Conecta al CSV Reader. Ejecuta y abre la vista.

En la tabla de Statistics, localiza y anota:

- promedio\_acumulado → Media (debe estar cerca de 3.2), Min (~1.0), Max (~4.9)
- asistencia\_pct → Media (~73%), Min (~35%), Max (100%)
- materias\_reprobadas → Media (~1.8), Max (~8)

**Interpretación:** un promedio general de ~3.2 con desviación de ~0.65 indica una distribución normal centrada en rendimiento medio. La asistencia media del 73% con un mínimo de 35% señala estudiantes con problemas graves de ausentismo que vale la pena investigar.

PASO  
3

### Contar estudiantes por estado académico

Arrastra GroupBy al canvas. Conecta al CSV Reader. Doble clic para configurar:

Pestaña Groups:

- Column: estado\_academico

Pestaña Manual Aggregation:

- Column: codigo | Method: Count | Result column: total\_estudiantes

Ejecuta. Abre Output View. Verás 4 filas: DESTACADO, REGULAR, SEGUIMIENTO, RIESGO con sus conteos.

Agrega el nodo Sorter después del GroupBy para ordenar por total\_estudiantes de mayor a menor:

- Sort criteria: total\_estudiantes | Order: Descending

## Calcular riesgo por programa

Este paso requiere dos instancias de GroupBy encadenadas para calcular el porcentaje de riesgo por programa.

GroupBy 1 — conecta al CSV Reader:

- Groups: programa, estado\_academico
- Aggregation: codigo → Count → n\_estudiantes

GroupBy 2 — conecta al GroupBy 1:

- Groups: programa
- Aggregation: n\_estudiantes → Sum → total\_programa

Math Formula — conecta ambos GroupBy con un nodo Joiner primero:

- Joiner: Join Column = programa en ambas tablas (Inner Join)
- Math Formula:  $\$n\_estudiantes\$ / \$total\_programa\$ * 100.0$
- Nombre columna resultado: pct\_estado

Agrega un Row Filter para quedarte solo con estado\_academico = RIESGO:

- Column: estado\_academico | Operator: = | Value: RIESGO

Ordena por pct\_estado descendente con Sorter para ver los programas con más riesgo primero.

PASO  
4

### Resultado esperado (valores del dataset sintético):

| Programa                   | Total | En Riesgo | % Riesgo |
|----------------------------|-------|-----------|----------|
| Ingeniería Industrial      | ~38   | ~8        | ~21%     |
| Derecho                    | ~32   | ~7        | ~22%     |
| Psicología                 | ~28   | ~5        | ~18%     |
| Administración de Empresas | ~38   | ~6        | ~16%     |
| Contaduría Pública         | ~32   | ~3        | ~9%      |
| Ingeniería de Sistemas     | ~32   | ~2        | ~6%      |

PASO

## Crear gráfica de barras

## 5

Busca Bar Chart en Node Repository. Conecta al GroupBy del paso 3 (el que tiene total por estado). Doble clic:

- Category Column: estado\_academico
- Value Columns: total\_estudiantes
- Title: Distribución de Estados Académicos — UTB 2025

Ejecuta y abre la vista. Verás un gráfico de barras con los 4 estados.

Para exportar la gráfica: clic derecho en la vista → Save as PNG → guarda en C:/KNIME\_UTB/resultados/

## PASO 6

### Exportar todo a Excel

Agrega Excel Writer. Conecta al Sorter del paso 4 (tabla de riesgo por programa). Configura:

- File: riesgo\_por\_programa.xlsx
- Sheet Name: Riesgo por Programa
- Open file after execution: activado

También conecta un segundo Excel Writer al GroupBy del paso 3 con Sheet Name: Distribución General.

## Interpretación de resultados — Ejercicio 1

Los datos sintéticos del dataset están diseñados para reflejar patrones realistas. Al terminar el Ejercicio 1 deberías poder responder:

| Pregunta                              | Hallazgo esperado                                                                       |
|---------------------------------------|-----------------------------------------------------------------------------------------|
| <b>Pregunta 1 — Estados</b>           | REGULAR es el estado más frecuente (~42%). RIESGO afecta al ~16% del total.             |
| <b>Pregunta 2 — Mayor riesgo</b>      | Derecho e Ingeniería Industrial suelen tener el mayor % de riesgo (diseño del dataset). |
| <b>Pregunta 3 — Promedio más bajo</b> | El programa con menor promedio promedio generalmente coincide con el de mayor riesgo.   |

## Ejercicio 2 — Perfilamiento de estudiantes: RIESGO vs DESTACADO

**Objetivo:** Comparar el perfil académico y socioeconómico de los estudiantes en estado RIESGO contra los DESTACADOS, para identificar los factores que más diferencian ambos grupos y formular recomendaciones institucionales.

### Preguntas para responder en este ejercicio

| #          | Pregunta de análisis                                                                    |
|------------|-----------------------------------------------------------------------------------------|
| Pregunta 1 | ¿Cuál es la diferencia en asistencia promedio entre estudiantes en RIESGO y DESTACADOS? |
| Pregunta 2 | ¿Los estudiantes becados tienen mejores promedios que los que no tienen beca?           |
| Pregunta 3 | ¿Existe relación entre el estrato socioeconómico y el estado académico?                 |
| Pregunta 4 | ¿En qué semestres se concentran más los estudiantes en RIESGO?                          |

### Paso a paso — Ejercicio 2

PASO  
1

#### Separar los grupos con Row Filter

Abre el workflow EDA\_Riesgo\_Academico\_UTB o crea uno nuevo. En ambos casos, empieza desde el CSV Reader del dataset.

Agrega dos nodos Row Filter (uno por grupo):

Row Filter 1 — Grupo RIESGO:

- Column: estado\_academico | Operator: = | Value: RIESGO
- Salida: 31 filas (estudiantes en riesgo)

Row Filter 2 — Grupo DESTACADO:

- Column: estado\_academico | Operator: = | Value: DESTACADO
- Salida: 22 filas (estudiantes destacados)

Ejecuta ambos filtros y verifica los conteos en Output View.

PASO  
2

#### Calcular estadísticas por grupo

Conecta un nodo Statistics a cada Row Filter (necesitarás 2 instancias de Statistics):  
Statistics → Grupo RIESGO: muestra min/max/media de promedio, asistencia, materias reprobadas.

Statistics → Grupo DESTACADO: mismas métricas para comparar.

Abre ambas vistas en paralelo (Window → New Editor Window) y compara los valores:

| Variable                     | Grupo RIESGO | Grupo DESTACADO | Diferencia    |
|------------------------------|--------------|-----------------|---------------|
| Promedio acumulado (media)   | ~2.4         | ~4.1            | ~1.7 puntos   |
| Asistencia % (media)         | ~58%         | ~91%            | ~33 puntos    |
| Materias reprobadas (media)  | ~3.8         | ~0.2            | ~3.6 materias |
| Satisfacción carrera (media) | ~2.9         | ~4.3            | ~1.4 puntos   |

**Hallazgo clave:** la diferencia más grande entre grupos es la asistencia (33 puntos porcentuales), seguida por las materias reprobadas. Esto sugiere que la asistencia es el factor más predictivo del riesgo académico en este dataset.

### Analizar beca y estado académico

Para responder la Pregunta 2, conecta un GroupBy al CSV Reader (no a los filtros): GroupBy de becas:

- Groups: tipo\_beca
- Aggregation: promedio\_acumulado → Mean → prom\_beca | asistencia\_pct → Mean → asist\_beca

Ordena por prom\_beca descendente con Sorter.

Abre Output View. Resultado esperado:

| tipo_beca  | prom_beca | asist_beca |
|------------|-----------|------------|
| EXCELENCIA | 4.12      | 89.3%      |
| BIENESTAR  | 3.31      | 76.4%      |
| ICETEX     | 3.18      | 73.2%      |
| SIN_BECA   | 3.05      | 71.8%      |

Interpretación: los becados de excelencia tienen el mayor promedio y asistencia. Sin embargo, la diferencia entre SIN\_BECA e ICETEX es menor de lo esperado, lo que sugiere que la motivación del estudiante es más determinante que el tipo de apoyo financiero.

PASO  
3

# PASO 4

## Analizar distribución por semestre

Para responder la Pregunta 4, usa otro GroupBy sobre los datos filtrados de RIESGO: GroupBy sobre Row Filter RIESGO:

- Groups: semestre
- Aggregation: codigo → Count → n\_en\_riesgo

Conecta un Bar Chart a este GroupBy:

- Category Column: semestre
- Value Columns: n\_en\_riesgo
- Title: Estudiantes en Riesgo por Semestre

Resultado esperado: los semestres 1 y 2 concentran la mayor cantidad de estudiantes en riesgo (~8-10 de los 31 totales). Esto es consistente con la literatura sobre transición a la vida universitaria.

**Recomendación institucional derivada:** implementar un programa de mentoría intensiva para estudiantes de primer año, especialmente en los programas de Derecho e Ingeniería, durante los dos primeros semestres.

# PASO 5

## Crear reporte ejecutivo multi-hoja en Excel

El reporte final del Ejercicio 2 debe tener 4 hojas de Excel. Usa 4 nodos Excel Writer, cada uno con un Sheet Name diferente. Para redirigir datos a hojas del mismo archivo, usa la opción 'Append' del segundo, tercero y cuarto Writer:

| Hoja Excel                                   | Contenido                                                     |
|----------------------------------------------|---------------------------------------------------------------|
| <b>Hoja 1:</b><br><b>Comparativo_Grupos</b>  | Tabla de comparación RIESGO vs DESTACADO (del Paso 2)         |
| <b>Hoja 2:</b> <b>Análisis_Becas</b>         | Tabla de promedio y asistencia por tipo de beca (del Paso 3)  |
| <b>Hoja 3:</b><br><b>Riesgo_por_Semestre</b> | Tabla de estudiantes en riesgo por semestre (del Paso 4)      |
| <b>Hoja 4:</b> <b>Datos_Limpios</b>          | Dataset completo después del procesamiento (desde CSV Reader) |

Configura el primer Excel Writer con el nombre del archivo: perfil\_estudiantil\_UTB.xlsx. Los otros tres usan la opción 'Append to existing file' y el mismo nombre, cada uno con su Sheet Name distinto.



## Workflow completo del Ejercicio 2

| Nodo                | Función                                                         |
|---------------------|-----------------------------------------------------------------|
| CSV Reader          | Carga datos_academicos_UTB.csv — fuente de todos los análisis   |
| Row Filter × 2      | Separa grupos RIESGO (31 filas) y DESTACADO (22 filas)          |
| Statistics × 2      | Estadísticas descriptivas para cada grupo — comparación directa |
| GroupBy (becas)     | Promedio y asistencia por tipo de beca                          |
| Sorter (becas)      | Ordena de mayor a menor promedio                                |
| GroupBy (semestres) | Conteo de estudiantes en RIESGO por semestre                    |
| Bar Chart           | Gráfica de barras: riesgo por semestre                          |
| Excel Writer × 4    | Exporta reporte multi-hoja perfil_estudiantil_UTB.xlsx          |

## Solución de errores comunes — Ejercicio 2

| Error                                    | Solución                                                                                                                                  |
|------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------|
| GroupBy produce 0 filas                  | Verifica que el tipo de datos de estado_academico es String, no numérico. El valor debe ser exactamente 'RIESGO' con mayúsculas.          |
| Bar Chart no muestra la columna          | La columna de categoría debe ser String y la de valores debe ser numérica. Si semestre es String, usa String to Number antes del GroupBy. |
| Excel Append sobrescribe todo            | Asegúrate de que el primer Writer tiene 'Create new' y los siguientes tienen 'Append'. El orden de ejecución importa.                     |
| Statistics no muestra todas las columnas | Statistics solo procesa columnas numéricas. Las columnas String (programa, genero) no aparecen — eso es normal.                           |

### Tarea integradora

Combina los resultados de ambas guías: usa el workflow de la Guía 1 para clasificar solicitudes, y el de la Guía 2 para analizar si los estudiantes en RIESGO generan más solicitudes de tipo APOYO. Para eso, une los datasets por codigo\_estudiante usando el nodo Joiner en KNIME.