

TALLER PRÁCTICO — SESIÓN 14

Limpiar y Preparar el Dataset de Ventas

KNIME Analytics Platform | UTB

Objetivo del taller

El participante aplica los nodos de limpieza de KNIME para diagnosticar, corregir y validar un conjunto de datos (dataset) de ventas con errores intencionales, documentando cada transformación en la bitácora.

Archivos necesarios

- *ventas_sinteticas.csv*

PARTE 1 — Diagnóstico del Dataset

Antes de limpiar, debemos entender qué problemas tiene el dataset. Esta fase de diagnóstico es fundamental.

1.1 Importar el dataset

PASO1

Crear nuevo workflow en KNIME

Abrir KNIME Analytics Platform
File > New KNIME Workflow... → nombre: 'S14_Limpieza_Ventas'
Click derecho en el lienzo → Add Node → buscar 'CSV Reader'

PASO2

Configurar el CSV Reader

Doble click en CSV Reader → Configure
Browse → seleccionar *ventas_sinteticas.csv*
Verificar que detecta el delimitador coma (,)
Activar 'Has column header' → OK
Ejecutar (F7) y verificar que carga 210 filas

1.2 Estadísticas iniciales

PASO3

Agregar nodo Statistics

Buscar nodo: 'Statistics'
Conectar CSV Reader → Statistics
Ejecutar y abrir la tabla de resultados
Registrar en la bitácora: conteo de missing por columna

Problemas esperados en el dataset

- ~25 valores faltantes en columnas: *producto, ciudad, vendedor, mes*
- 10 filas duplicadas exactas
- 12 filas con cantidad como texto (ej: '15 unid')
- 8 filas con precio con símbolo \$ (ej: '\$ 245000')
- Ciudades con formato inconsistente (mayúsculas, minúsculas)

- 6 fechas con formato diferente (ej: '03/2024' en lugar de '2024-03')
- 1 cantidad anómala (9999), 1 precio negativo (-50000), 1 total en cero

PARTE 2 — Limpieza Paso a Paso

Construir el workflow de limpieza conectando nodos en secuencia. Cada nodo transforma el dataset y lo pasa al siguiente.

2.1 Seleccionar columnas relevantes

PASO4

Column Filter — seleccionar las 8 columnas del dataset

Agregar nodo: Column Filter

Conectar Statistics (o CSV Reader) → Column Filter

Configurar: incluir solo id_venta, producto, ciudad, vendedor, mes, cantidad, precio_unitario, total_venta

Ejecutar y verificar que el dataset tiene exactamente 8 columnas

Documentar en bitácora: columnas eliminadas (ninguna en este caso)

2.2 Eliminar duplicados

PASO5

Duplicate Row Filter — eliminar filas repetidas

Agregar nodo: Duplicate Row Filter

Conectar Column Filter → Duplicate Row Filter

Configurar: comparar por TODAS las columnas

Seleccionar 'Keep first occurrence'

Ejecutar → verificar: puerto superior = filas únicas (~200), puerto inferior = duplicados (~10)

Documentar en bitácora: cantidad de duplicados eliminados

2.3 Corregir tipos de datos — texto a numérico

PASO6

String Manipulation — limpiar columna 'cantidad'

Agregar nodo: String Manipulation

Conectar Duplicate Row Filter → String Manipulation

Expresión: `regexReplace($cantidad$, " unid", "")`

Nombre nueva columna: cantidad_limpia

Luego agregar nodo: String to Number para convertir a entero

Documentar en bitácora: transformación de tipo de dato

PASO7

String Manipulation — limpiar columna 'precio_unitario'

Agregar otro nodo: String Manipulation

Expresión: `regexReplace($precio_unitario$, "\\$", "")`

Nombre nueva columna: precio_limpio

Conectar String to Number para convertir a decimal

Documentar en bitácora

2.4 Normalizar texto de ciudades

PASO8

String Manipulation — estandarizar ciudades

Agregar nodo: String Manipulation

Conectar al flujo anterior → String Manipulation

Expresión: `capitalize(lowerCase(trim($ciudad$)))`

Nombre nueva columna: `ciudad_normalizada`

Verificar resultado: todas las ciudades con mayúscula inicial

Documentar en bitácora

2.5 Tratar valores faltantes

PASO9

Missing Value — estrategia por columna

Agregar nodo: Missing Value

Columna 'producto': reemplazar con moda (valor más frecuente)

Columna 'ciudad': reemplazar con moda

Columna 'vendedor': reemplazar con 'No registrado'

Columna 'mes': eliminar fila (dato crítico no imputar)

Ejecutar y verificar 0 valores faltantes en Statistics

Documentar en bitácora la estrategia de cada columna

2.6 Filtrar valores atípicos

PASO10

Row Filter — eliminar datos fuera de rango

Agregar nodo: Row Filter

Condición 1: `cantidad_limpiar <= 500` (eliminar cantidad 9999)

Condición 2: `precio_limpiar > 0` (eliminar precio negativo)

Conectar dos Row Filter en secuencia

Verificar en resultado: filas anómalas eliminadas

Documentar en bitácora con criterio de negocio usado

2.7 Crear columna calculada

PASO11

Math Formula — calcular margen estimado

Agregar nodo: Math Formula

Expresión: `$precio_limpiar$ * $cantidad_limpiar$ * 0.15`

Nombre nueva columna: `margen_estimado`

Verificar que todos los valores son positivos

Documentar en bitácora: fórmula y justificación de negocio

2.8 Normalizar variables numéricas

PASO12

Normalizer — escalar precio a rango 0-1

Agregar nodo: Normalizer

Seleccionar columna: `precio_limpiar`

Método: Min-Max Normalization (0 a 1)
Nombre columna resultante: precio_normalizado
Ejecutar y verificar rango entre 0 y 1
Documentar en bitácora

PARTE 3 — Validación y Comparación

3.1 Estadísticas finales

PASO13

Statistics — validar dataset limpio

Agregar nodo: Statistics al final del workflow
Ejecutar y comparar con las estadísticas iniciales (Paso 3)
Verificar todos los criterios del checklist de calidad
Tomar nota de: filas iniciales vs finales, columnas antes vs después

3.2 Exportar dataset limpio

PASO14

CSV Writer — guardar resultado final

Agregar nodo: CSV Writer al final del workflow
Configurar ruta de salida: ventas_limpias_S14.csv
Activar 'Write column header'
Ejecutar y verificar que el archivo se creó correctamente