

# TALLER PRÁCTICO — SESIÓN 14

## Limpiar y Preparar el Dataset de Ventas

KNIME Analytics Platform | UTB

### Objetivo del taller

*El participante aplica los nodos de limpieza de KNIME para diagnosticar, corregir y validar un conjunto de datos (dataset) de ventas con errores intencionales, documentando cada transformación en la bitácora.*

### Archivos necesarios

- *ventas\_sinteticas.csv*

## PARTE 1 — Diagnóstico del Dataset

Antes de limpiar, debemos entender qué problemas tiene el dataset. Esta fase de diagnóstico es fundamental.

### 1.1 Importar el dataset

#### PASO1

##### Crear nuevo workflow en KNIME

Abrir KNIME Analytics Platform  
File > New KNIME Workflow... → nombre: 'S14\_Limpieza\_Ventas'  
Click derecho en el lienzo → Add Node → buscar 'CSV Reader'

#### PASO2

##### Configurar el CSV Reader

Doble click en CSV Reader → Configure  
Browse → seleccionar *ventas\_sinteticas\_con\_errores.csv*  
Verificar que detecta el delimitador coma (,)  
Activar 'Has column header' → OK  
Ejecutar (F7) y verificar que carga 210 filas

### 1.2 Estadísticas iniciales

#### PASO3

##### Agregar nodo Statistics

Buscar nodo: 'Statistics'  
Conectar CSV Reader → Statistics  
Ejecutar y abrir la tabla de resultados  
Registrar en la bitácora: conteo de missing por columna

### Problemas esperados en el dataset

- ~25 valores faltantes en columnas: *producto, ciudad, vendedor, mes*
- 10 filas duplicadas exactas
- 12 filas con cantidad como texto (ej: '15 unid')
- 8 filas con precio con símbolo \$ (ej: '\$ 245000')
- Ciudades con formato inconsistente (mayúsculas, minúsculas)

- 6 fechas con formato diferente (ej: '03/2024' en lugar de '2024-03')
- 1 cantidad anómala (9999), 1 precio negativo (-50000), 1 total en cero

## PARTE 2 — Limpieza Paso a Paso

Construir el workflow de limpieza conectando nodos en secuencia. Cada nodo transforma el dataset y lo pasa al siguiente.

### 2.1 Seleccionar columnas relevantes

#### PASO4

##### Column Filter — seleccionar las 8 columnas del dataset

Agregar nodo: Column Filter

Conectar Statistics (o CSV Reader) → Column Filter

Configurar: incluir solo id\_venta, producto, ciudad, vendedor, mes, cantidad, precio\_unitario, total\_venta

Ejecutar y verificar que el dataset tiene exactamente 8 columnas

Documentar en bitácora: columnas eliminadas (ninguna en este caso)

### 2.2 Eliminar duplicados

#### PASO5

##### Duplicate Row Filter — eliminar filas repetidas

Agregar nodo: Duplicate Row Filter

Conectar Column Filter → Duplicate Row Filter

Configurar: comparar por TODAS las columnas

Seleccionar 'Keep first occurrence'

Ejecutar → verificar: puerto superior = filas únicas (~200), puerto inferior = duplicados (~10)

Documentar en bitácora: cantidad de duplicados eliminados

### 2.3 Corregir tipos de datos — texto a numérico

#### PASO6

##### String Manipulation — limpiar columna 'cantidad'

Agregar nodo: String Manipulation

Conectar Duplicate Row Filter → String Manipulation

Expresión: regexReplace(\$cantidad\$, " unid", "")

Nombre nueva columna: cantidad\_limpia

Luego agregar nodo: String to Number para convertir a entero

Documentar en bitácora: transformación de tipo de dato

#### PASO7

##### String Manipulation — limpiar columna 'precio\_unitario'

Agregar otro nodo: String Manipulation

Expresión: `regexReplace($precio_unitario$, "\\$ ", "")`  
Nombre nueva columna: `precio_limpio`  
Conectar String to Number para convertir a decimal  
Documentar en bitácora

## 2.4 Normalizar texto de ciudades

### PASO8

#### String Manipulation — estandarizar ciudades

Agregar nodo: String Manipulation  
Conectar al flujo anterior → String Manipulation  
Expresión: `capitalize(lowerCase(trim($ciudad$)))`  
Nombre nueva columna: `ciudad_normalizada`  
Verificar resultado: todas las ciudades con mayúscula inicial  
Documentar en bitácora

## 2.5 Tratar valores faltantes

### PASO9

#### Missing Value — estrategia por columna

Agregar nodo: Missing Value  
Columna 'producto': reemplazar con moda (valor más frecuente)  
Columna 'ciudad': reemplazar con moda  
Columna 'vendedor': reemplazar con 'No registrado'  
Columna 'mes': eliminar fila (dato crítico no imputar)  
Ejecutar y verificar 0 valores faltantes en Statistics  
Documentar en bitácora la estrategia de cada columna

## 2.6 Filtrar valores atípicos

### PASO10

#### Row Filter — eliminar datos fuera de rango

Agregar nodo: Row Filter  
Condición 1: `cantidad_limpia <= 500` (eliminar cantidad 9999)  
Condición 2: `precio_limpio > 0` (eliminar precio negativo)  
Conectar dos Row Filter en secuencia  
Verificar en resultado: filas anómalas eliminadas  
Documentar en bitácora con criterio de negocio usado

## 2.7 Crear columna calculada

## PASO11

### Math Formula — calcular margen estimado

Agregar nodo: Math Formula

Expresión:  $\$precio\_limpio\$ * \$cantidad\_limpia\$ * 0.15$

Nombre nueva columna: margen\_estimado

Verificar que todos los valores son positivos

Documentar en bitácora: fórmula y justificación de negocio

## 2.8 Normalizar variables numéricas

## PASO12

### Normalizer — escalar precio a rango 0-1

Agregar nodo: Normalizer

Seleccionar columna: precio\_limpio

Método: Min-Max Normalization (0 a 1)

Nombre columna resultante: precio\_normalizado

Ejecutar y verificar rango entre 0 y 1

Documentar en bitácora

## PARTE 3 — Validación y Comparación

---

### 3.1 Estadísticas finales

## PASO13

### Statistics — validar dataset limpio

Agregar nodo: Statistics al final del workflow

Ejecutar y comparar con las estadísticas iniciales (Paso 3)

Verificar todos los criterios del checklist de calidad

Tomar nota de: filas iniciales vs finales, columnas antes vs después

### 3.2 Exportar dataset limpio

## PASO14

### CSV Writer — guardar resultado final

Agregar nodo: CSV Writer al final del workflow

Configurar ruta de salida: ventas\_limpias\_S14.csv

Activar 'Write column header'

Ejecutar y verificar que el archivo se creó correctamente